UNIVERSIDAD PANAMERICANA

PROYECTO DE REGULARIZACIÓN, PCA Y MARKOWITZ

FUNDAMENTOS DE ECONOMETRÍA

Dr. César Galindo – Otoño 2026

Datos

Rendimientos mensuales en porcentaje de 30 portafolios de industria de EE. UU., con el factor de mercado `Mkt-RF` y la tasa libre de riesgo `RF` (Kenneth R. French Data Library, 2000-01 a 2026-09). El archivo `datos/industrias_ff30_mensual.csv` y el notebook guiado están en `https://github.com/IvliCaesar/Proyecto-Econometria-Regularizacion-PCA-Markowitz`. Define los rendimientos en exceso restando `RF`. El periodo de *entrenamiento* son los primeros 240 meses (2000-01 a 2019-12) y el de *prueba*, los últimos 81 (2020-01 a 2026-09).

Con la matrícula de un integrante como semilla, `rng = numpy.random.default_rng(SEMILLA)`, sobre la lista de sectores en el orden del archivo, elige primero el sector objetivo, `rng.choice(sectores)`, y después los activos del portafolio, `rng.choice(sectores, size=12, replace=False)`.

Parte 1. Regresión lineal, Ridge, Lasso y Elastic Net (25 puntos)

Se comparan los estimadores que minimizan:

$$\text{MCO: } \|y - X\beta\|^2, \qquad \text{Ridge: } \|y - X\beta\|^2 + \lambda\|\beta\|_2^2,$$
$$\text{Lasso: } \tfrac{1}{2n}\|y - X\beta\|^2 + \lambda\|\beta\|_1, \qquad \text{Elastic Net: } \tfrac{1}{2n}\|y - X\beta\|^2 + \lambda\big[\rho\|\beta\|_1 + \tfrac{1-\rho}{2}\|\beta\|_2^2\big].$$

Ejercicio 1.1 (En papel).

a) Deduce $\hat{\beta}_{\text{Ridge}} = (X^\top X + \lambda I)^{-1} X^\top y$. Si $X = UDV^\top$ es la descomposición en valores singulares, demuestra que Ridge multiplica cada componente de $\hat{\beta}_{\text{MCO}}$ en la dirección v_j por $d_j^2/(d_j^2 + \lambda)$. ¿Qué direcciones se encogen más?

b) Si $X^\top X = nI$ y $z_j = X_j^\top y/n$, encuentra $\hat{\beta}_j$ para Ridge y para Lasso con las funciones objetivo de arriba.

c) Con ese resultado, explica por qué Lasso produce ceros exactos y Ridge no.

Ejercicio 1.2 (Replicar un sector). Regresa el exceso del sector objetivo sobre los excesos de los otros 29 sectores.

a) Estima MCO con los datos de entrenamiento. Reporta R^2, R^2 ajustada, el estadístico F y cuántas pendientes son significativas al 5 %.

b) Ajusta Ridge, Lasso y Elastic Net, estandarizando las regresoras con los datos de entrenamiento y eligiendo λ por validación cruzada de 5 bloques, solo con esos datos.

c) Para los cuatro métodos, reporta en una tabla el RMSE de entrenamiento y de prueba, la R^2 de prueba, el número de coeficientes distintos de cero y la norma de los coeficientes estandarizados.

d) Grafica las trayectorias de los coeficientes en función de λ para Ridge y para Lasso.

e) Repite el inciso c) entrenando solo con los últimos $n \in \{36, 60, 120, 240\}$ meses de entrenamiento. Grafica el RMSE de prueba contra n.

f) Comprueba numéricamente las fórmulas del Ejercicio 1.1 a) con $\lambda = 100$.

g) Con muestra completa, aplica la prueba de Diebold-Mariano a $d_t = e^2_{\text{MCO},t} - e^2_{\text{Ridge},t}$ en el periodo de prueba: regresa d_t sobre una constante, con errores estándar HAC de 3 rezagos.

h) ¿Qué método gana con cada n, y por cuánto? ¿La diferencia es significativa? ¿Por qué una sola ventana no basta para concluir?

Ejercicio 1.3 (Monte Carlo). Simula $X_{ij} = \sqrt{\varrho}\, z_i + \sqrt{1-\varrho}\, e_{ij}$ y $y = X\beta + 1.5\,\varepsilon$, con z_i, e_{ij} y ε_i normales estándar independientes. Cruza las condiciones:

- colinealidad: $\varrho \in \{0.1,\ 0.95\}$;
- verdad: *escasa* (3 coeficientes iguales a ± 1 y el resto cero) o *densa* (todos normales, reescalados a $\|\beta\| = \sqrt{3}$);
- datos: *abundantes* ($n = 200$, $p = 20$) o *escasos* ($n = 40$, $p = 30$).

Para cada uno de los 8 escenarios y 4 métodos, haz 20 réplicas con una muestra independiente y 500 observaciones de prueba. Registra el vector de respuestas ($\log \text{RMSE},\ \log\|\hat\beta - \beta\|$) y resume ambas respuestas en una tabla de método por escenario.

Ejercicio 1.4 (Tabla MANOVA). Con los datos del Ejercicio 1.3, considera los factores método ($a = 4$) y escenario ($b = 8$), con $r = 20$ réplicas.

a) Calcula directamente las matrices de sumas de cuadrados y productos cruzados

$$H_A = br \sum_i (\bar y_{i\cdot} - \bar y)(\bar y_{i\cdot} - \bar y)^\top, \qquad H_B = ar \sum_j (\bar y_{\cdot j} - \bar y)(\bar y_{\cdot j} - \bar y)^\top,$$

$$H_{AB} = r \sum_{i,j} (\bar y_{ij} - \bar y_{i\cdot} - \bar y_{\cdot j} + \bar y)(\bar y_{ij} - \bar y_{i\cdot} - \bar y_{\cdot j} + \bar y)^\top, \qquad E = \sum_{i,j,k} (y_{ijk} - \bar y_{ij})(y_{ijk} - \bar y_{ij})^\top,$$

y verifica que $H_A + H_B + H_{AB} + E = T$, la matriz total.

b) Si $\theta_1, \ldots, \theta_s$ son los valores propios de $E^{-1}H$, calcula para cada efecto

$$\Lambda = \prod_i \frac{1}{1+\theta_i}, \qquad V = \sum_i \frac{\theta_i}{1+\theta_i}, \qquad T_{HL} = \sum_i \theta_i, \qquad R = \max_i \theta_i.$$

c) Compara con `statsmodels` y presenta la tabla MANOVA: efecto, estadístico, valor, grados de libertad, F, valor p y $\eta^2 = 1 - \Lambda^{1/s}$, con $s = \min(\text{respuestas}, gl_H)$.

d) Realiza una ANOVA por respuesta con corrección de Bonferroni. Calcula la razón entre la mayor y la menor varianza residual entre celdas. ¿Se cumple la igualdad de covarianzas? ¿Qué tanto puedes confiar en los valores p?

e) ¿Cuál estadístico reportas como principal y por qué? ¿Qué renglón de la tabla responde a la pregunta de si la conveniencia de un método depende del caso?

Ejercicio 1.5 (Conclusión). Indica si la regularización mejora a MCO en predicción y en estimación de β, y qué método prefieres, en cada situación: muchos datos con baja colinealidad; muchos datos con alta colinealidad; pocos datos con verdad escasa; pocos datos con verdad densa. Justifica con tus cifras. ¿Qué pierdes al usar Lasso frente a MCO si tu objetivo es hacer inferencia sobre un coeficiente?

Parte 2. Multicolinealidad (15 puntos)

Usa los datos de Longley (`statsmodels`), con $y =$ `TOTEMP` y las otras seis variables como regresoras. Recuerda que $\mathrm{VIF}_j = 1/(1 - R_j^2)$.

Ejercicio 2.1 (En papel). Con dos regresoras de correlación r, demuestra que $\mathrm{VIF}_1 = \mathrm{VIF}_2 = 1/(1-r^2)$. Si $r = 0.95$, ¿cuánto vale el VIF y por cuánto se multiplica el error estándar de cada coeficiente?

Ejercicio 2.2 (Diagnóstico). Calcula el VIF y la tolerancia de cada regresora, y el número de condición de X estandarizada. Estima MCO y compara la significancia conjunta con la individual.

Ejercicio 2.3 (Inestabilidad). Reestima MCO omitiendo una observación a la vez. Reporta para cada pendiente el mínimo y el máximo, e indica cuáles cambian de signo.

Ejercicio 2.4 (Remedios). Compara por error de validación *leave-one-out*, VIF máximo y número de condición (cuando apliquen):

a) MCO con todas las regresoras;

b) MCO sin `GNP` ni `POP`;

c) MCO con `GNP`/(`GNPDEFL` · `POP`), `UNEMP` y `ARMED`;

d) regresión sobre los componentes principales que acumulen 95 % de la varianza (PCR);

e) mínimos cuadrados parciales con 2 componentes (PLS);

f) Ridge, con λ elegida por validación cruzada.

Ejercicio 2.5 (Centrar). Calcula el VIF máximo de las regresoras de Longley antes y después de centrarlas. Haz lo mismo con $\{x, x^2\}$ y $\{x - \bar{x}, (x - \bar{x})^2\}$, donde $x =$ `UNEMP`. ¿Cuándo sirve centrar, y por qué?

Ejercicio 2.6 (Sectores). Calcula los VIF y el número de condición de las regresoras del Ejercicio 1.2 y compáralos con los de Longley.

Ejercicio 2.7 (Conclusión). ¿Qué remedio eliges si se busca interpretar el efecto de cada variable? ¿Y si solo se busca predecir? ¿La multicolinealidad sesga a MCO? ¿Cuándo no hace falta corregirla?

Parte 3. PCA a partir de un vector aleatorio (15 puntos)

Sea $X \in \mathbb{R}^p$ un vector aleatorio con media μ y covarianza Σ.

Ejercicio 3.1 (Teoría). Plantea $\max_a \mathrm{Var}(a^\top X)$ sujeto a $a^\top a = 1$ y demuestra, con multiplicadores de Lagrange, que a es vector propio de Σ y que la varianza máxima es el mayor valor propio. Demuestra que $Y_k = a_k^\top (X - \mu)$ cumple $\mathrm{Var}(Y_k) = \lambda_k$ y $\mathrm{Cov}(Y_j, Y_k) = 0$ para $j \neq k$. En papel, para $\Sigma = \left(\begin{smallmatrix} 2 & 1 \\ 1 & 2 \end{smallmatrix}\right)$, encuentra los componentes y la varianza explicada, y haz tres iteraciones del método de la potencia desde $v_0 = (1, 0)^\top$.

Ejercicio 3.2 (Población). Con `default_rng(SEMILLA + 3)`, genera una matriz ortogonal Q de 5×5 (factorización QR de una matriz normal) y define $\Sigma = Q\,\mathrm{diag}(8,\ 3,\ 1.5,\ 0.5,\ 0.2)\,Q^\top$ y μ normal. Calcula los valores y vectores propios, y la varianza explicada acumulada.

Ejercicio 3.3 (Direcciones aleatorias). Sortea 20 000 direcciones unitarias a al azar y grafica el histograma de $a^\top \Sigma a$. Verifica que $\lambda_{\text{mín}} \le a^\top \Sigma a \le \lambda_{\text{máx}}$.

Ejercicio 3.4 (Muestra). Genera $n \in \{30, 100, 1000, 10\,000\}$ realizaciones de $X \sim N(\mu, \Sigma)$. Reporta $\hat{\lambda}_1$ y el ángulo $\arccos |\hat{a}_1^\top a_1|$. Verifica que la covarianza muestral de los Y_k es aproximadamente $\operatorname{diag}(\lambda_k)$.

Ejercicio 3.5 (Vector inicial aleatorio). Sin rutinas de valores propios, implementa el método de la potencia desde un vector aleatorio unitario v_0,

$$v_{t+1} = \frac{\Sigma v_t}{\|\Sigma v_t\|}, \qquad \hat{\lambda} = v^\top \Sigma v,$$

y la deflación $\Sigma \leftarrow \Sigma - \hat{\lambda}_1 \hat{a}_1 \hat{a}_1^\top$ para obtener los cinco componentes.

a) Compara con el Ejercicio 3.2.

b) Grafica en escala logarítmica el error angular por iteración, junto con la tasa $(\lambda_2/\lambda_1)^t$.

c) ¿Qué ocurre si $\lambda_2/\lambda_1 \approx 1$? ¿Y si $v_0 \perp a_1$? ¿Por qué elegir v_0 al azar resuelve este último caso?

Ejercicio 3.6 (Sectores). Aplica tu método a la matriz de correlación de los 30 sectores, en entrenamiento. Reporta la varianza explicada por los primeros 5 componentes, las cargas del primero y su correlación con `Mkt-RF`. Interpreta el primer componente. ¿Qué implica para la diversificación y para la multicolinealidad?

Parte 4. Solución a Markowitz (15 puntos)

Para los 12 activos asignados, sean μ y Σ la media y la covarianza anualizadas (entrenamiento), y r_f la tasa libre anualizada. Define

$$A = \mathbf{1}^\top \Sigma^{-1} \mu, \qquad B = \mu^\top \Sigma^{-1} \mu, \qquad C = \mathbf{1}^\top \Sigma^{-1} \mathbf{1}, \qquad D = BC - A^2.$$

Ejercicio 4.1 (Teoría). Para $\min_w \frac{1}{2} w^\top \Sigma w$ sujeto a $w^\top \mu = m$ y $w^\top \mathbf{1} = 1$, demuestra que

$$w = \delta\, \Sigma^{-1} \mu + \gamma\, \Sigma^{-1} \mathbf{1}, \qquad \delta = \frac{Cm - A}{D}, \quad \gamma = \frac{B - Am}{D}, \qquad \sigma^2(m) = \frac{Cm^2 - 2Am + B}{D}.$$

Deduce el portafolio de mínima varianza global (GMV), $w_g = \Sigma^{-1}\mathbf{1}/C$, y el tangente, $w_t = \Sigma^{-1}(\mu - r_f \mathbf{1})/(A - C r_f)$. ¿Qué falla si $r_f \ge A/C$? En papel, con dos activos de volatilidades 20 % y 30 % y correlación 0.25, calcula los pesos de GMV y su volatilidad.

Ejercicio 4.2 (Implementación). Programa la solución cerrada. Verifica las restricciones y la fórmula de $\sigma^2(m)$, y compara los pesos con un optimizador numérico.

Ejercicio 4.3 (Frontera). Grafica la frontera eficiente con y sin ventas en corto, los activos, GMV, el portafolio tangente y la línea del mercado de capitales. Verifica que el Sharpe tangente es $\sqrt{B - 2Ar_f + Cr_f^2}$.

Ejercicio 4.4 (Dos fondos). Para un rendimiento m dado, encuentra α tal que $w_m = \alpha w_g + (1-\alpha) w_t$ y verifícalo numéricamente.

Ejercicio 4.5 (Fuera de muestra). Con pesos estimados en entrenamiento, rebalanceo mensual y sin costos, compara en el periodo de prueba: 1/N; GMV muestral; tangente muestral; GMV con covarianza de Ledoit-Wolf; GMV con covarianza de 3 componentes principales más la diagonal residual; y tangente sin ventas en corto. Reporta rendimiento, volatilidad, Sharpe en prueba y en entrenamiento, máxima caída, mayor peso absoluto y suma de pesos cortos, además del número de condición de cada covarianza.

Ejercicio 4.6 (Estabilidad). Remuestrea 200 veces los meses de entrenamiento (*bootstrap*), recalcula los pesos de la tangente y de GMV, y compara sus rangos intercuartiles. ¿Por qué difieren?

Ejercicio 4.7 (Reestimación). Al inicio de cada año del periodo de prueba, estima con los 60 meses anteriores y conserva los pesos 12 meses. Compara 1/N, GMV muestral, GMV con Ledoit-Wolf, tangente muestral y tangente sin ventas en corto. ¿Qué le ocurre a la tangente muestral, y por qué?

Ejercicio 4.8 (Conclusión). ¿Cuál estrategia ganó fuera de muestra, con pesos fijos y con reestimación? ¿Cuánto se perdió entre el Sharpe de entrenamiento y el de prueba? Explica las analogías: Ledoit-Wolf es a Markowitz lo que Ridge es a MCO, y la covarianza de PCA es a Markowitz lo que PCR es a MCO. ¿Recomendarías la solución cerrada a un fondo real? ¿Qué limitaciones tiene tu prueba?

Parte 5. Dashboard, presentación oral y documentación (30 puntos)

Ejercicio 5.1 (Dashboard). Publica tus resultados en un dashboard interactivo, en Streamlit o en una página HTML, con una sección y al menos un control por cada una de las cuatro partes. Incluye la tabla MANOVA y la comparación dentro y fuera de muestra.

Ejercicio 5.2 (Memorándum). En un máximo de 250 palabras, dirigidas al comité de inversión de un fondo y sin usar el término *valor propio*, indica qué método usarías para replicar tu sector y cómo construirías el portafolio. Incluye tres cifras de tu análisis y una limitación.

Ejercicio 5.3 (Presentación oral). Presenta oralmente tu dashboard, en vivo, ante profesores. Todos los integrantes exponen y deben poder responder preguntas sobre cualquier parte del proyecto y sobre su código.

Ejercicio 5.4 (Documentación y reproducibilidad). Documenta tu notebook: portada con integrantes y semilla; antes de cada paso, qué vas a hacer y por qué; comentarios en el código; después de cada tabla o gráfica, una interpretación con tus cifras, y fuentes utilizadas. El notebook debe correr de principio a fin, sin errores, con la semilla declarada.